

# Estadística

Estudia las técnicas para recolectar, reunir y ordenar datos y <sup>para</sup> inferir resultados a partir de los datos recolectados.

Ejemplo: Supongamos que interesa estudiar la altura de los estudiantes de la facultad. Se toman al azar  $n$  estudiantes y a cada uno se le mide la altura. Tenemos  $n$  datos tal que asentamos  $x_1, x_2, \dots, x_n$ .

Población → conjunto de todos los objetos de interés. Los estudiantes de la facultad

Muestra → una parte de la población. La muestra toma al azar ( $n$  se eligen de la población  $N$  alumnos al azar como si se eligieran bolillos de una urna con  $N$  bolillos). Se hace un muestreo aleatorio simple.

La característica que importa estudiar es la altura de los alumnos. Se define  $X$ : "altura de un estudiante tomado al azar".

En estadística, la distribución de  $X$  es desconocida. Los únicos datos disponibles son las mediciones  $x_1, x_2, \dots, x_n$ .

Estadística descriptiva: es la parte de estadística que estudia la muestra, es decir, estudia y ordena la muestra.

Estadística inferencial: estudia como inferir resultados a partir de la muestra sobre la población.

En el ejemplo nos puede interesar  $\mu = E(X)$  que es desconocido. Si partimos de  $x_1, x_2, \dots, x_n$  se trata de "estimar" un valor de  $\mu$ . (Se sea de alguna forma obtener algún valor aproximado de  $\mu$ ).

Entonces al tener una muestra, queremos obtener el verdadero valor de  $\mu$  poniéndole solamente  $n$  valores de la población.

Tenemos las mediciones  $x_1, x_2, \dots, x_n$ . Podemos asumir que  $x_i$  es el resultado de medir la RA  $X_i$ : "altura del alumno  $i$ "  $i=1, 2, \dots, n$

Si las mediciones se hacen bajo las mismas condiciones, podemos asumir que  $x_1, x_2, \dots, x_n$  tienen la misma distribución y que es igual a la distribución de la RA  $X$  original.

Además supondremos que  $x_1, x_2, \dots, x_n$  son independientes.

Entonces se dice que  $x_1, x_2, \dots, x_n$  es una muestra aleatoria de la RA  $X$ .

Si interesa inferir algún valor para la  $\mu = E(X)$  (desconocida), es razonable estimar  $\mu$  con  $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ . Se busca que la estimación sea este lo más cerca posible al verdadero valor de  $\mu$ .

Si tenemos una muestra de  $n$  alumnos, y obtenemos otros valores  $x'_1, x'_2, \dots, x'_n$ , entonces tendremos otra estimación  $\bar{x}'$  para  $\mu$ .

Podemos considerar que  $\bar{X}$  y  $\tilde{X}'$  son observaciones diferentes que toma la ra  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ , donde ahora  $X_1, X_2, \dots, X_n$  son las variables de una muestra aleatoria.

Dicimos que  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$  es un estimador puntual de  $\mu$  y los valores  $\bar{x}$  y  $\tilde{x}'$  son estimaciones de  $\mu$ .

En general si tenemos una ra que es una función de la muestra aleatoria, se dice que esa ra es un estadístico.

$\bar{X}$  es un estadístico. Cuando se usa un estadístico para estimar un parámetro desconocido se dice que el estadístico es un estimador puntual.

En el ejemplo  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$  es un estimador puntual de  $\mu$ . Mientras que  $\bar{x}$  y  $\tilde{x}'$  (valores que toma  $\bar{X}$ ) son estimaciones puntuales de  $\mu$ .

Notación: Si queremos a cualquier parámetro desconocido con  $\theta$  y con  $\hat{\theta}$  al estimador puntual de  $\theta$ . En el ejemplo:  $\hat{\mu} = \bar{X}$

Podemos considerar a cualquier estadístico como estimador puntual de un parámetro desconocido.

Entonces necesitamos criterios para considerar que estadístico es "mejor" estimador puntual.

Criterios para evaluar estimadores puntuales:

$$\hat{\mu} = \bar{X} \quad \begin{matrix} \xrightarrow{\bar{x}_1} \\ \xrightarrow{\bar{x}_2} \\ \xrightarrow{\bar{x}_3} \\ \vdots \\ \xrightarrow{\bar{x}_n} \end{matrix}$$

Estimador insesgado: Sea  $\hat{\theta}$  un estimador puntual de  $\theta$ , donde  $\theta$  es un parámetro desconocido. Si  $E(\hat{\theta}) = \theta$  se dice que  $\hat{\theta}$  es un estimador insesgado de  $\theta$  (cuálquier sea el valor de  $\theta$ )  $\rightarrow$  el valor verdadero

Ejemplo: sea  $X_1, X_2, \dots, X_n$  muestra aleatoria de una ra  $X$  donde  $\mu = E(X)$  desconocida. Sea  $\hat{\mu} = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ . Sabemos que  $\hat{\mu} = \bar{X}$  es un estimador insesgado de  $\mu$ , este es:  $E(\bar{X}) = \mu$  cuálquier sea el valor de  $\mu$ .

$$E(\hat{\mu}) = E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} E\left(\sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n E(X_i) = \frac{1}{n} \sum_{i=1}^n \mu$$

$$\rightarrow \frac{1}{n} \cdot n\mu = \mu = E(\bar{X}) \quad \text{cuálquier sea el valor de } \mu.$$

Sea  $X_1, X_2, \dots, X_n$  muestra aleatoria de una ra  $X$  con  $\mu = E(X)$  y  $\sigma^2 = V(X)$  ambos desconocidos. El estadístico que vamos regularmente para estimar  $\sigma^2$  es:

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \quad \hat{\sigma}^2 = S^2 \text{ varianza muestral}$$

$\hat{\sigma}^2 = S^2$  es un estimador insesgado de  $\sigma^2$  m.s. Sabemos que

$$\left[ \sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n X_i^2 - n\bar{X}^2 \right] \rightarrow E(S^2) = E\left(\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2\right)$$

$$= \frac{1}{n-1} E\left(\sum_{i=1}^n (X_i - \bar{X})^2\right) = \frac{1}{n-1} E\left(\sum_{i=1}^n X_i^2 - n\bar{X}\right) = \frac{1}{n-1} [E(\sum X_i^2) - nE(\bar{X}^2)]$$

$$= \frac{1}{n-1} \left[ \sum_{i=1}^n E(X_i^2) - nE(\bar{X})^2 \right] \otimes \quad E(\bar{X}^2) = V(\bar{X}) + (E(\bar{X}))^2 \quad V(X) = E(X^2) - (E(X))^2$$

$$= \frac{\sigma^2}{n} + \mu^2 \quad E(X^2) = V(X) + (E(X))^2 = \sigma^2 + \mu^2$$

$$\textcircled{*} \quad = \frac{1}{n-1} \left[ \sum (\sigma^2 + \mu^2) - n \left( \frac{\sigma^2}{n} + \mu^2 \right) \right] = \frac{1}{n-1} [n(\sigma^2 + \mu^2) - \sigma^2 - n\mu^2]$$

$$= \frac{1}{n-1} [n\sigma^2 + n\mu^2 - \sigma^2 - n\mu^2] = \frac{\sigma^2(n-1)}{n-1} = \sigma^2$$

Observaciones

① si  $X_1, X_2, X_3, \dots, X_n$  es una muestra aleatoria de una ra  $X$  aleatoria  $X$  con  $\mu = E(X)$  y  $\sigma^2 = V(X)$  desconocida, entonces:  $\hat{\mu}^2 = \bar{X}^2$  no es un estimador inexpresivo de  $\mu^2$  pues:

$$E(\hat{\mu}^2) = E(\bar{X}^2) = \underbrace{V(\bar{X})}_{\frac{\sigma^2}{n}} + (E(\bar{X}))^2 = \frac{\sigma^2}{n} + \mu^2 \neq \mu^2$$

Ley de un estimador puntual:  $b(\hat{\theta}) = E(\hat{\theta}) - \theta$ . Entonces en el ej anterior:  $b(\hat{\mu}^2) = b(\bar{X}^2) = E(\bar{X}^2) - \mu^2$ .

$$= \frac{\sigma^2}{n} + \mu^2 - \mu^2 = \boxed{\frac{\sigma^2}{n}}$$

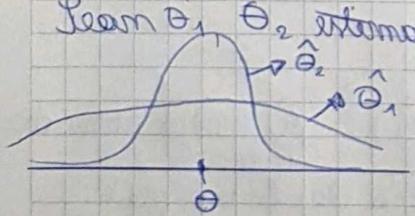
Notar que el  $\bar{X}$  tiende a cero cuando el tamaño de la muestra tiende a infinito, entonces  $\bar{X}^2$  es un estimador de  $\mu^2$  asintóticamente inexpresivo

General:  $S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{X})^2}$  no es un estimador inexpresivo de  $\sigma$ .

Se verifica si tiene de una  $X \sim N(\mu, \sigma)$

→ si  $\hat{\theta}$  es un estimador puntual de  $\theta$  tal que  $b(\hat{\theta}) = 0$  entonces  $b(\hat{\theta}) = E(\hat{\theta}) - \theta = 0$ , o sea  $\hat{\theta}$  es un estimador inexpresivo de  $\theta$

Sean  $\hat{\theta}_1, \hat{\theta}_2$  estimadores inexpresivos de  $\theta$ . Ora  $E(\hat{\theta}_1) = \theta$  y  $E(\hat{\theta}_2) = \theta$



Consideremos mejor estimador puntual de  $\theta$  a aquel que tenga menor varianza. Es decir que si  $V(\hat{\theta}_1) > V(\hat{\theta}_2)$ , consideramos mejor estimador de  $\theta$  a  $\hat{\theta}_2$ .

Ej.  $X_1, X_2, \dots, X_7$  muestra aleatoria de ra  $X$  con  $\mu = E(X)$  y  $\sigma^2 = V(X)$   
Sean  $\hat{\mu}_1 = \bar{X} = \frac{1}{7} \sum_{i=1}^7 x_i$  y  $\hat{\mu}_2 = \frac{x_1 + x_7}{2}$

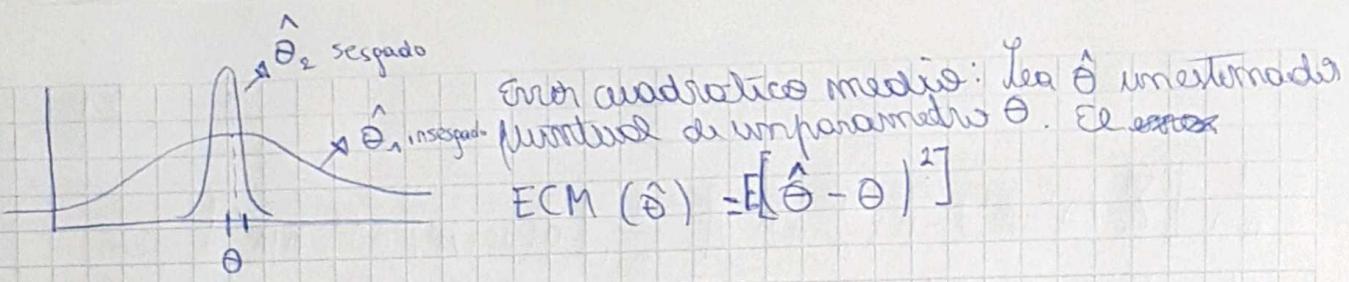
$$E(\hat{\mu}_1) = E(\bar{X}) = \mu \quad E(\hat{\mu}_2) = E\left(\frac{x_1 + x_7}{2}\right) = \frac{1}{2} (E(x_1) + E(x_7)) = \frac{1}{2} 2\mu = \mu$$

Amboos inexpresivos, vean las varianzas.

$$V(\hat{\mu}_1) = V(\bar{X}) = \boxed{\frac{\sigma^2}{7}} \quad V(\hat{\mu}_2) = V\left(\frac{x_1 + x_7}{2}\right) = \frac{1}{4} (V(x_1) + V(x_7))$$

Como  $V(\hat{\mu}_1) < V(\hat{\mu}_2)$  y considera que  $\hat{\mu}_1$  es mejor estimador puntual que  $\hat{\mu}_2$

$$= \frac{1}{4} (\sigma^2 + \sigma^2) = \boxed{\frac{\sigma^2}{2}}$$



Observaciones:

① Si  $\hat{\theta}$  es un estimador insesgado de  $\theta$ , entonces  $E(\hat{\theta}) = \theta$ , o sea  $ECM(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2] = V(\hat{\theta})$  y  $V(\lambda) = E[(X - E(X))^2] = E(X^2) - (E(X))^2$

② Se puede probar que  $ECM(\hat{\theta}) = V(\hat{\theta}) + (b(\hat{\theta}))^2$

En general si  $\hat{\theta}_1$  y  $\hat{\theta}_2$  son 2 estimadores puntuales de un parámetro  $\theta$ , se considera mejor estimador de  $\theta$  aquél que tenga menor  $ECM$ .

Ej.: Sea  $X_1, X_2, \dots, X_n$  muestra aleatoria de un rango  $X$  con  $E(X) = M$  y  $\sigma^2 = V(X)$ .

Consideremos  $\hat{\mu}_1 = \frac{1}{7} \sum_{i=1}^7 X_i = \bar{X}$      $\hat{\mu}_3 = \frac{2X_1 - X_2 + X_3}{3}$

$\rightarrow ECM(\hat{\theta}) = V(\hat{\theta}) + (b(\hat{\theta}))^2$

$$E(\hat{\mu}_1) = E(\bar{X}) = M \quad \therefore b(\hat{\mu}_1) = 0$$

$$V(\hat{\mu}_1) = \frac{\sigma^2}{7} \quad \rightarrow ECM(\hat{\mu}_1) = V(\hat{\mu}_1) + 0 = \frac{\sigma^2}{7}$$

$$\begin{aligned} E(\hat{\mu}_3) &= E\left(\frac{2X_1 - X_2 + X_3}{3}\right) = \frac{1}{3}(2E(X_1) - E(X_2) + E(X_3)) \\ &= \frac{1}{3}(2M - M + M) = \frac{2}{3}M \quad \rightarrow b(\hat{\mu}_3) = E(\hat{\mu}_3) - M = \frac{2}{3}M - M = \boxed{-\frac{M}{3}} \end{aligned}$$

$$\begin{aligned} V(\hat{\mu}_3) &= V\left(\frac{2X_1 - X_2 + X_3}{3}\right) = \left(\frac{1}{3}\right)^2 (4V(X_1) + V(X_2) + V(X_3)) = \frac{1}{9}(4\sigma^2 + \sigma^2 + \sigma^2) \\ &= \frac{2}{3}\sigma^2 \end{aligned}$$

$$\rightarrow ECM(\hat{\mu}_3) = \frac{2}{3}\sigma^2 + \left(-\frac{M}{3}\right)^2 = \frac{2}{3}\sigma^2 + \frac{M^2}{9}$$

Notar que  $\frac{2}{3}\sigma^2 > \frac{1}{7}\sigma^2 \therefore \frac{2}{3}\sigma^2 + \frac{M^2}{9} > \frac{1}{7}\sigma^2$

$\therefore E(M(\hat{\mu}_3)) > ECM(\hat{\mu}_1)$  ∴  $\hat{\mu}_3$  es mejor estimador de  $M$ .

Estimadores consistentes: Sea  $X_1, X_2, \dots, X_n$  muestra aleatoria de  $X$ .  
Sea  $\hat{\theta}_n$  un estimador puntual de  $\theta$ .

Se dice que  $\hat{\theta}_n$  es un estimador consistente de  $\theta$

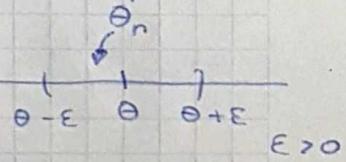
$$\lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| > \varepsilon) \rightarrow 0 \quad \forall \varepsilon > 0$$

$$\text{o } P\left(\lim_{n \rightarrow \infty} |\hat{\theta}_n - \theta| \leq \varepsilon\right) \rightarrow 1 \quad \forall \varepsilon > 0$$

Se puede probar el sig. teorema:

Teorema: Sea  $\hat{\theta}_n$  un estimador puntual de  $\theta$ . Si el sesgo de  $b(\hat{\theta}_n) \xrightarrow{n \rightarrow \infty} 0$  ( $\theta = E(\hat{\theta}_n) \xrightarrow{n \rightarrow \infty} \theta$ ) y  $V(\hat{\theta}_n) \xrightarrow{n \rightarrow \infty} 0$  entonces  $\hat{\theta}_n$  es un estimador consistente de  $\theta$

La reciproca no es válida.



Se puede probar que  $S^2$  es un estimador consistente de  $\sigma^2$   
 $\bar{X}$  es un estimador consistente de  $\mu$ .

### Métodos para construir estimadores puntuales

#### Método de los momentos

Sea  $X_1, \dots, X_n$  muestra aleatoria de una r.v.  $X$ . Asumimos que se conoce la familia de distribuciones a la que pertenece  $X$ .

Sean  $\theta_1, \dots, \theta_r$  los parámetros desconocidos de la distribución de  $X$ .

Definimos:  $E(X^k)$  como el  $k$ -ésimo momento poblacional, donde  $k=1, 2, 3, \dots, n$ . Si  $k=1$ , entonces tenemos  $E(X)$ .

$\frac{1}{n} \sum_{i=1}^n X_i^k$  es el  $k$ -ésimo momento muestral con  $k=1, 2, 3, \dots$

Si  $k=1$ , tenemos  $\bar{X}$

Se puede probar que:  $P\left(\left|\frac{1}{n} \sum_{i=1}^n X_i^k - E(X^k)\right| > \epsilon\right) \rightarrow 0$   $n \rightarrow \infty$

Entonces el método de los momentos, para estimar  $\theta_1, \theta_2, \dots, \theta_r$ , consiste en plantear:

$$\begin{cases} \frac{1}{n} \sum_{i=1}^n X_i = E(X) \\ \frac{1}{n} \sum_{i=1}^n X_i^2 = E(X^2) \\ \vdots \\ \frac{1}{n} \sum_{i=1}^n X_i^r = E(X^r) \end{cases} \quad \begin{array}{l} \text{se resuelve y encuentra estimadores} \\ \text{para } \theta_1, \theta_2, \dots, \theta_r (E(X), E(X^2), \dots, E(X^r)) \\ \text{quedan expresados en función de} \\ \theta_1, \theta_2, \dots, \theta_r \end{array}$$

queda un sistema de  $r$  ecuaciones con  $r$  incógnitas

Ej. Sea  $X_1, \dots, X_n$  muestra aleatoria de una r.v.  $X$ , donde  $X \sim N(\mu, \sigma^2)$ . Hallar estimaciones puntuales para  $\mu$  y  $\sigma^2$  por el método de los momentos.

$$\theta_1 = \mu, \quad \theta_2 = \sigma^2$$

$$\begin{aligned} \frac{1}{n} \sum_{i=1}^n X_i &= E(X) \quad \text{Sabiendo que } E(X) = \mu \quad \text{y } E(X^2) = V(X) + (E(X))^2 = \sigma^2 + \mu^2 \\ \frac{1}{n} \sum_{i=1}^n X_i^2 &= E(X^2) \quad \begin{cases} \frac{1}{n} \sum_{i=1}^n X_i = \mu & \text{①} \\ \frac{1}{n} \sum_{i=1}^n X_i^2 = \sigma^2 + \mu^2 & \text{②} \end{cases} \quad \text{De ①} \rightarrow \hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X} \\ & \text{De ②} \rightarrow \sigma^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \mu^2 = \frac{1}{n} \sum_{i=1}^n X_i - \bar{X}^2 \end{aligned}$$

$$\therefore \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

Observación:

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{1}{n} \underbrace{\left( \sum_{i=1}^n X_i^2 - n \bar{X}^2 \right)}_{\sum (X_i - \bar{X})^2} \quad \therefore \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

Notar que

$$\begin{aligned} \hat{\sigma}^2 &= \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{n-1}{n} \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \left(\frac{n-1}{n}\right) S^2 \\ E(\hat{\sigma}^2) &= E\left(\left(\frac{n-1}{n}\right) S^2\right) = \left(\frac{n-1}{n}\right) E(S^2) = \left(\frac{n-1}{n}\right) \sigma^2 \neq \sigma^2 \end{aligned}$$

Introducir el método de los momentos no produce, en general, estimadores insesgados.

Ej) Sea  $x_1, \dots, x_n$  muestra aleatoria de una r.v.  $X$ ,  $X \sim p(1)$ . Hallar estimador puntual con el método de los momentos.

$$\theta_1 = \lambda$$

$$\frac{1}{n} \sum_{i=1}^n x_i = E(X) \rightarrow \frac{1}{n} \sum_{i=1}^n x_i = \lambda \therefore \boxed{\hat{\lambda} = \bar{x}}$$

Ej): Sea  $x_1, \dots, x_n$  una muestra aleatoria de una r.v.  $X$ ,  $X \sim N(0, \sigma^2)$ . Hallar estimador de  $\sigma^2$  por el método de los momentos.

$$\frac{1}{n} \sum_{i=1}^n x_i = E(X) \rightarrow \frac{1}{n} \sum_{i=1}^n x_i = 0 \quad X \text{ no tiene variancia } \sigma^2$$

$$\frac{1}{n} \sum_{i=1}^n x_i^2 = E(X^2) = V(X) = \sigma^2 \therefore \boxed{\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n x_i^2}$$

$$V(X) = E(X^2) - (E(X))^2$$

$$V(X) = E(X^2) - 0^2$$

Ej) Sea  $x_1, \dots, x_n$  muestra aleatoria de una r.v.  $X$ , donde la densidad de  $X$  está dada por:

$$f(x) = \begin{cases} \frac{\theta}{2^\theta} x^{\theta-1} & 0 < x < 2 \\ 0 & \text{cc} \end{cases} \quad \text{Hallar estimador puntual de } \theta \text{ por el método de los momentos.}$$

Densidad: Supongamos que para hallarla planteamos  $\int_{-\infty}^{\infty} f(x) dx = 1$

$$1 = \int_0^2 \frac{\theta}{2^\theta} x^{\theta-1} dx = \frac{\theta}{2^\theta} \int_0^2 x^{\theta-1} dx = \frac{\theta}{2^\theta} \left( \frac{x^\theta}{\theta} \right) \Big|_0^2 = \frac{\theta}{2^\theta} \left( \frac{2^\theta}{\theta} - \frac{0^\theta}{\theta} \right) = \frac{\theta}{2^\theta} \cdot \frac{2^\theta}{\theta} = 1$$

$$\text{Planteamos: } \frac{1}{n} \sum_{i=1}^n x_i = E(X) \quad \textcircled{1}$$

$$\text{Calculamos } E(X) = \int_0^2 x \left( \frac{\theta}{2^\theta} x^{\theta-1} \right) dx = \frac{\theta}{2^\theta} \int_0^2 x^\theta dx = \frac{\theta}{2^\theta} \left( \frac{x^{\theta+1}}{\theta+1} \right) \Big|_0^2 \\ = \frac{\theta}{2^\theta} \left( \frac{2^{\theta+1}}{\theta+1} - \frac{0^{\theta+1}}{\theta+1} \right) = \frac{\theta}{2^\theta} \left( \frac{2^{\theta+1}}{\theta+1} - 0 \right) = \frac{2\theta}{\theta+1}$$

$$\textcircled{1} \quad \frac{1}{n} \sum_{i=1}^n x_i = \frac{2\theta}{\theta+1} \rightarrow (\theta+1)\bar{x} = 2\theta \rightarrow \theta\bar{x} + \bar{x} = 2\theta \rightarrow \bar{x} = 2\theta - \theta\bar{x}$$

$$\rightarrow \boxed{\theta = \frac{\bar{x}}{2-\bar{x}}}$$

Método de máxima verosimilitud

Sea  $x_1, \dots, x_n$  muestra aleatoria de una r.v.  $X$ . Asumimos conocida la familia de distribuciones a la que pertenece  $X$ .

Sea  $\theta$  un parámetro desconocido de la dist. de  $X$ .

Supongamos que  $X$  es una r.v. discreta.

Supongamos que  $x_1, x_2, \dots, x_n$  es una observación de la muestra  $(x_1, x_2, \dots, x_n)$  respectivamente).

Planteamos  $P(X_1=x_1, X_2=x_2, \dots, X_n=x_n)^{\text{indep}}$

$$= P(X_1=x_1) \cdot P(X_2=x_2) \cdot \dots \cdot P(X_n=x_n) = L(x_1, x_2, \dots, x_n, \theta) \text{ función de verosimilitud}$$

Notar que  $P(X=x_i)$  puede escribirse en función de  $\theta$ . El método de máxima verosimilitud consiste en hallar aquel valor de  $\theta$  que maximiza la función de verosimilitud  $L(x_1, x_2, \dots, x_n, \theta)$  (la cual es una probabilidad).

Ej) Sea  $X_1, X_2, \dots, X_n$  muestra de una r.v.  $X, X \sim P(\lambda)$ . Hallar el EMV de  $\lambda$ .

Planteamos la función de verosimilitud  $L(x_1, x_2, \dots, x_n, \lambda) = P(X_1=x_1), P(X_2=x_2), \dots$

$$P(X_n=x_n) = \frac{e^{-\lambda} \lambda^{x_1}}{x_1!} \cdot \frac{e^{-\lambda} \lambda^{x_2}}{x_2!} \cdots \frac{e^{-\lambda} \lambda^{x_n}}{x_n!}$$

$$= \left( e^{-\lambda} \right)^n \lambda^{\sum_{i=1}^n x_i} = \frac{e^{-\lambda n} \lambda^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n x_i!} \quad \text{Para facilitar se toma } \ln(L(x_1, x_2, \dots, x_n, \lambda))$$

es estrictamente creciente

$$\rightarrow \ln(L(x_1, x_2, \dots, x_n, \lambda)) = \ln \left( \frac{e^{-\lambda n} \lambda^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n x_i!} \right) = \ln(e^{-\lambda n}) + \ln(\lambda^{\sum_{i=1}^n x_i}) - \ln(\prod_{i=1}^n x_i!)$$

$$\rightarrow \ln(e^{-\lambda n}) + \ln(\lambda^{\sum_{i=1}^n x_i}) - \ln(\prod_{i=1}^n x_i!) = (-\lambda n) \cdot 1 + \sum_{i=1}^n x_i \ln \lambda - \ln(\prod_{i=1}^n x_i!)$$

$$\frac{d}{d\lambda} \ln L(x_1, x_2, \dots, x_n, \lambda) \rightarrow -n + \left( \sum_{i=1}^n x_i \right) \frac{1}{\lambda} = 0$$

$$\therefore n = \left( \sum_{i=1}^n x_i \right) \frac{1}{\lambda} \rightarrow \lambda = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x} \Rightarrow \text{se puede verificar que } L(x_1, x_2, \dots, x_n, \lambda) \text{ tiene en } \lambda = \bar{x} \text{ un}$$

$$\therefore \boxed{\lambda = \frac{1}{n} \sum_{i=1}^n x_i}$$

Ej): Sea  $X_1, X_2, \dots, X_n$  muestra aleatoria de una r.v.  $X, X \sim B(1, p)$

Supongamos que interesa estimar la proporción de artículos defectuosos fabricados por una máquina en 1 día.

Tomaremos una muestra de artículos de toda la producción. Para cada artículo redefine  $x_i = \begin{cases} 1 & \text{si el artículo es defectuoso} \\ 0 & \text{si el artículo es bueno} \end{cases}$

$$\rightarrow X_i \sim B(1, p) \quad i = 1, 2, \dots, n$$

$$\text{Le quiere hallar EMV def. } P(X=x_i) = \binom{n}{x_i} p^{x_i} (1-p)^{1-x_i} = p^{x_i} (1-p)^{1-x_i}$$

$$\rightarrow L(x_1, x_2, \dots, x_n, p) = P(X_1=x_1, X_2=x_2, \dots, X_n=x_n)$$

$$= P(X_1=x_1) \cdot P(X_2=x_2) \cdots P(X_n=x_n)$$

$$= p^{x_1} (1-p)^{1-x_1} \cdot p^{x_2} (1-p)^{1-x_2} \cdots \cdot p^{x_n} (1-p)^{1-x_n}$$

$$\rightarrow = p^{\sum_{i=1}^n x_i} (1-p)^{n - \sum_{i=1}^n x_i} = p^{\sum_{i=1}^n x_i} (1-p)^{n - \sum_{i=1}^n x_i}$$

$$\ln(L(x_1, x_2, \dots, x_n, p)) = \ln(p^{\sum_{i=1}^n x_i}) + \ln((1-p)^{n - \sum_{i=1}^n x_i}) = \sum_{i=1}^n x_i \cdot \ln(p) + (n - \sum_{i=1}^n x_i) \cdot \ln(1-p)$$

$$\frac{d}{dp} \ln(L(x_1, x_2, \dots, x_n, p)) = \left( \sum_{i=1}^n x_i \right) \frac{1}{p} + (n - \sum_{i=1}^n x_i) \frac{1}{1-p} = 0 \quad \text{regla de la cadena}$$

$$\therefore \left( \sum_{i=1}^n x_i \right) \frac{1}{p} = (n - \sum_{i=1}^n x_i) \frac{1}{1-p} \rightarrow \frac{1-p}{p} = \frac{n - \sum_{i=1}^n x_i}{\sum_{i=1}^n x_i} \rightarrow \frac{1}{p} - 1 = \frac{n}{\sum_{i=1}^n x_i} - 1$$

$$\rightarrow \frac{1}{P} = \frac{n}{\sum x_i} \rightarrow P = \frac{\sum_{i=1}^n x_i}{n} = \bar{x} \rightarrow \hat{P} = \frac{1}{n} \sum_{i=1}^n x_i$$

E) b) i) Se seleccionan n=10 chips fabricados por una compañía. Si son defectuosos

$$y \sum_{i=1}^{100} x_i = 5 \therefore \text{la estimación de } P \text{ es } \bar{x} = \frac{1}{100} \sum_{i=1}^{100} x_i = \frac{5}{100} = 0,05$$

(caso continuo)

Si  $x_1, x_2, \dots, x_n$  es una muestra aleatoria de una va  $X$  continua con densidad  $f(x)$  y si  $x_1, x_2, \dots, x_n$  es una medición de la muestra aleatoria, entonces se toma:

$L(x_1, x_2, \dots, x_n, \theta) = f(x_1) \cdot f(x_2) \cdots f(x_n)$ . Se toma como estimación de  $\theta$  a aquel valor que maximiza  $L(x_1, x_2, \dots, x_n, \theta)$

Ej) Sea  $x_1, x_2, \dots, x_n$  muestra aleatoria de una va  $X$ ,  $X \sim \text{Exp}(\lambda)$

$$f(x) = \begin{cases} \lambda e^{-\lambda x} & \text{si } x \geq 0 \\ 0 & \text{si } x < 0 \end{cases} \rightarrow L(x_1, x_2, \dots, x_n, \lambda) = f(x_1) \cdot f(x_2) \cdots f(x_n)$$

$$= \lambda e^{-\lambda x_1} \cdot \lambda e^{-\lambda x_2} \cdots \lambda e^{-\lambda x_n}$$

$$= \lambda^n e^{-\sum_{i=1}^n \lambda x_i} = \lambda^n e^{-\lambda \sum x_i}$$

$$\ln(L(x_1, x_2, \dots, x_n, \lambda)) = \ln(\lambda^n) + \ln(e^{-\lambda \sum x_i}) = n \ln(\lambda) + (-\lambda \sum_{i=1}^n x_i) \quad (n \in \mathbb{N})$$

$$= n \ln(\lambda) - \lambda \sum_{i=1}^n x_i \rightarrow \frac{d}{d\lambda} \ln(L(x_1, x_2, \dots, x_n, \lambda)) = 0$$

$$\rightarrow \frac{n}{\lambda} - \sum_{i=1}^n x_i = 0 \rightarrow \lambda = \frac{n}{\sum_{i=1}^n x_i} \rightarrow \frac{\lambda}{\sum_{i=1}^n x_i} = 1 = \frac{1}{\bar{x}}$$

$$\therefore \hat{\lambda} = \frac{1}{\bar{x}}$$

Se determina la duración en hs de cada una de 10 lámparas donde los siguientes datos:

$$x_1 = 49,5 \quad x_2 = 101,5 \quad x_3 = 100,9,4 \quad x_4 = 173,4 \quad x_5 = 251,6$$

$$x_6 = 315 \quad x_7 = 130,1,4 \quad x_8 = 732,8 \quad x_9 = 660,6 \quad x_{10} = 1456,5$$

Se sospecha que la duración en hs tiene dist. exponencial.

a) Hallar el EMV del.

b) Hallar la estimación de  $\lambda$  para la muestra dada.

$X_i$ : "tiempo de vida en horas de una lámpara i"  $X_i \sim \text{Exp}(\lambda)$  ( $\lambda$  desconocida)  
se toma una muestra de 10 lámparas

$x_i$ : "duración en horas de la lámpara i"  $i = 1, 2, \dots, 10$

$x_1, x_2, \dots, x_{10}$  muestra aleatoria de la va  $X$ .

$x_1, x_2, \dots, x_{10}$  es una medición de la muestra aleatoria.

$$a) \hat{\lambda} = \frac{1}{\bar{x}} \quad b) \lambda = \frac{1}{\bar{x}} = \frac{1}{696,52} \text{ es la estimación de } \lambda \text{ para la muestra dada}$$

g) sea  $X_1, X_2, \dots, X_n$  muestra aleatoria de una r.a.X  $X \sim N(\mu, \sigma^2)$

Hallar EMV para  $\mu$  y  $\sigma^2$   $f(x) = \frac{1}{\sqrt{\sigma^2 2\pi}} e^{-\frac{1}{2\sigma^2}(x-\mu)^2}$

$$\begin{aligned} L(x_1, x_2, \dots, x_n, \mu, \sigma^2) &= f(x_1) \cdot f(x_2) \cdots f(x_n) \\ &= \frac{1}{\sqrt{\sigma^2 2\pi}} e^{-\frac{1}{2\sigma^2}(x_1-\mu)^2} \cdot \frac{1}{\sqrt{\sigma^2 2\pi}} e^{-\frac{1}{2\sigma^2}(x_2-\mu)^2} \cdots \frac{1}{\sqrt{\sigma^2 2\pi}} e^{-\frac{1}{2\sigma^2}(x_n-\mu)^2} \\ &= \left( \frac{1}{\sqrt{\sigma^2 2\pi}} \right)^n e^{-\frac{1}{2\sigma^2} \sum (x_i - \mu)^2} = \frac{1}{(\sigma^2 2\pi)^{n/2}} e^{-\frac{1}{2\sigma^2} \sum (x_i - \mu)^2} \\ \ln(L(x_1, x_2, \dots, x_n, \mu, \sigma^2)) &= \ln\left(\frac{1}{(\sigma^2 2\pi)^{n/2}}\right) + \ln\left(e^{-\frac{1}{2\sigma^2} \sum (x_i - \mu)^2}\right) \\ &= -\frac{n}{2} \ln(\sigma^2 2\pi) - \frac{1}{2\sigma^2} \sum (x_i - \mu)^2 \end{aligned}$$

$$\begin{cases} \frac{d}{d\mu} \ln(L(x_1, x_2, \dots, x_n, \mu, \sigma)) & \textcircled{1} \quad \textcircled{1} - \frac{1}{2\sigma^2} \sum 2(x_i - \mu) (-1) \\ \frac{d}{d\sigma} \ln(L(x_1, x_2, \dots, x_n, \mu, \sigma)) & \textcircled{2} \quad \textcircled{2} \left( \frac{n}{2} \right) \frac{1}{\sigma^2 2\pi} - \frac{1}{2} \sum (x_i - \mu)^2 \left( -\frac{1}{\sigma^4} \right) \end{cases}$$

$$\textcircled{1} \rightarrow \frac{1}{2\sigma^2} \sum 2(x_i - \mu) \cancel{(-1)} \rightarrow \frac{1}{\sigma^2} \sum (x_i - \mu) = 0$$

$$\rightarrow \sum (x_i - \mu) = 0 \rightarrow \sum x_i - \sum \mu = 0 \Rightarrow \sum x_i - n\mu = 0 \rightarrow \hat{\mu} = \frac{\sum x_i}{n} = \bar{x}$$

$$\textcircled{2} \left( -\frac{n}{2} \right) \frac{1}{\sigma^2 2\pi} - \frac{1}{2} \sum (x_i - \mu)^2 \left( -\frac{1}{\sigma^4} \right) \stackrel{0}{\Rightarrow} \frac{n}{\sigma^2} + \frac{1}{\sigma^4} \sum (x_i - \mu)^2 = 0$$

$$\rightarrow \frac{n}{\sigma^2} = \frac{1}{\sigma^4} \sum (x_i - \mu)^2 \rightarrow \frac{\sigma^4}{\sigma^2} = \frac{1}{n} \sum (x_i - \mu)^2 \Rightarrow \sigma^2 = \frac{1}{n} \sum (x_i - \bar{x})^2$$

$$\rightarrow \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

Importante recordar los resultados,

Propiedades de los EMV  $\rightarrow$  son válidas si la muestra es grande  
Bajo condiciones muy generales, se puede probar:

① Los EMV son asintóticamente invariados

② Son consistentes los EMV

③ Para muestras muy grandes, son asintóticamente de menor varianza

④ Propiedad de invarianza: sea  $\hat{\theta}$  es el EMV de  $\theta$ . Sea  $g(x)$  una función inyectiva. Entonces el EMV de  $g(\theta)$  es  $g(\hat{\theta})$

En el ejercicio anterior se encontró el EMV de  $\sigma^2$ .  $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$

Si queremos hallar el EMV de  $\sigma$ , usaremos la propiedad de invarianza.

$$\sigma = \sqrt{\sigma^2} \rightarrow \hat{\sigma} = \sqrt{\hat{\sigma}^2} = \sqrt{\frac{1}{n} \sum (x_i - \bar{x})^2}$$

En el ej de la bombilla. b) ii) Se pide el EMY de  $(1-p)^6$   $n=100$

$$\sum_{i=1}^{100} x_i = 5 \quad \hat{p} = \bar{x} \quad \text{La estimación para } p \text{ es } \hat{p} = \frac{5}{100} = 0,05$$

$p(p) = (1-p)^6$  ( $\circ$  sea  $x$  toman 6 chips y ninguno es defectuoso)  
el EMY de  $(1-p)^6 = g(\hat{p}) = g(\bar{x}) = (1-\bar{x})^6$  y la estimación  
para  $(1-p)^6$  es  $(1-0,05)^6$

En el ej de los lámparas:  $X$ : "duración en horas de una lámpara"

$$X_1, X_2, \dots, X_n \text{ m.a. dex. el EMY de } \lambda \rightarrow \hat{\lambda} = \frac{1}{\bar{x}}$$

$$\text{Hallar el EMY de } P(X < 1400) = 1 - e^{-\lambda \cdot 1400}$$

$$\therefore \text{el EMY es } 1 - e^{-\hat{\lambda} \cdot 1400} = 1 - e^{-\hat{\lambda} \cdot 1400} = 1 - e^{-\frac{1}{\bar{x}} \cdot 1400}$$

### Intervalos de confianza

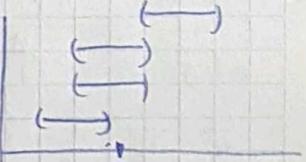
Sea  $X_1, X_2, \dots, X_n$  una muestra aleatoria de una r.a.X. Sea  $\theta$  un parámetro desconocido de la distribución de  $X$ . Un intervalo de confianza para  $\theta$  es un intervalo  $(\hat{\theta}_1, \hat{\theta}_2)$  donde  $\hat{\theta}_1$  y  $\hat{\theta}_2$  son estadísticos. De manera tal que  $P(\theta \in (\hat{\theta}_1, \hat{\theta}_2)) = 1 - \alpha$  con  $1 - \alpha$  fijo de antemano.  $(1 - \alpha) \cdot 100\%$  es el nivel de confianza del intervalo.

Si  $x_1, x_2, \dots, x_n$  es una medición de la muestra aleatoria entonces  $\hat{\theta}_1$  tomará el valor  $\hat{\theta}_1$  y  $\hat{\theta}_2$  tomará el valor  $\hat{\theta}_2$ .

Así para la medición  $x_1, x_2, \dots, x_n$  tenemos un intervalo numérico  $(\hat{\theta}_1, \hat{\theta}_2)$

Si  $x'_1, x'_2, \dots, x'_n$  es otra medición de la muestra aleatoria entonces obtenemos otro intervalo numérico  $(\hat{\theta}'_1, \hat{\theta}'_2)$

Fix  $\alpha = 0,95$ , entonces si tenemos 100 mediciones de la m.a. Nuevas a tener 100 intervalos numéricos de los cuales queremos que 95% contenga a  $\theta$



Al mayor nivel de confianza más precisión

La precisión de la estimación se aumenta con un intervalo de longitud pequeña

→ Intervalos de confianza para la media de una normal con varianza conocida:

Sea  $x_1, x_2, \dots, x_n$  m.a. de una r.a.X donde  $X \sim N(\mu, \sigma^2)$  con  $\sigma^2$  conocida. Se quiere un intervalo de confianza para  $\mu$  en nivel 95%.

Utilizaremos el método del punto

① Se toma un estimador puntual de  $\mu$   $\hat{\mu} = \bar{x}$

② Se construye a partir de  $\hat{\mu} = \bar{x}$  un estadístico

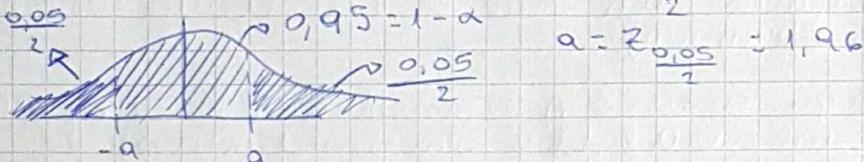
- debe contener a  $\mu$
- debe tener distribución conocida

consideramos el estadístico  $Z = \frac{\bar{X} - \mu}{\sqrt{\sigma^2/n}}$  notemos que  $\bar{X} \sim N(\mu, \sigma^2/n)$  y entonces  $Z \sim N(0, 1)$   
además  $Z$  contiene ap. d<sup>r</sup> q se le llama estadística punto.

Si conocemos la distribución de  $Z$  podemos plantear: hallar a tal que  $0,95 = P(-\alpha \leq Z \leq \alpha)$ . Si  $Z \sim N(0, 1)$ :

$$P(-\alpha \leq Z \leq \alpha) = \Phi(\alpha) - \Phi(-\alpha) = 2\Phi(\alpha) - 1$$

$$\rightarrow 0,95 = 2\Phi(\alpha) - 1 \rightarrow \Phi(\alpha) = \frac{1 - 0,95}{2} = 0,975 \quad \therefore \boxed{\alpha = 1,96}$$



$$\rightarrow 0,95 = (-1,96 \leq Z \leq 1,96) = \left( -1,96 \leq \frac{\bar{X} - \mu}{\sqrt{\sigma^2/n}} \leq 1,96 \right)$$

$$= P\left(-1,96 \sqrt{\frac{\sigma^2}{n}} \leq \bar{X} - \mu \leq 1,96 \sqrt{\frac{\sigma^2}{n}}\right) = P\left(-\bar{X} - 1,96 \sqrt{\frac{\sigma^2}{n}} \leq -\mu \leq -\bar{X} + 1,96 \sqrt{\frac{\sigma^2}{n}}\right)$$

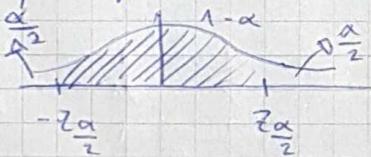
$$= P\left(\bar{X} + 1,96 \sqrt{\frac{\sigma^2}{n}} \geq \mu \geq -1,96 \sqrt{\frac{\sigma^2}{n}} + \bar{X}\right) = P\left(\bar{X} - 1,96 \sqrt{\frac{\sigma^2}{n}} \leq \mu \leq \bar{X} + 1,96 \sqrt{\frac{\sigma^2}{n}}\right)$$

$$= P\left(\mu \in \left(\bar{X} - 1,96 \sqrt{\frac{\sigma^2}{n}}, \bar{X} + 1,96 \sqrt{\frac{\sigma^2}{n}}\right)\right) \quad \therefore \left(\bar{X} - \frac{z_{0,05}}{2} \sqrt{\frac{\sigma^2}{n}}, \bar{X} + \frac{z_{0,05}}{2} \sqrt{\frac{\sigma^2}{n}}\right)$$

En general, un intervalo de confianza para  $\mu$  de nivel  $(1-\alpha)100\%$

será:

$$\left(\bar{X} - z_{\frac{\alpha}{2}} \sqrt{\frac{\sigma^2}{n}}, \bar{X} + z_{\frac{\alpha}{2}} \sqrt{\frac{\sigma^2}{n}}\right)$$



$z_{\frac{\alpha}{2}}$  → valor crítico

Se usan tablas de valores críticos → del área a la derecha (el complemento)  $P(X \geq x)$

$\frac{\alpha}{2}$

Ejemplo. Se ve que el límite de elasticidad de una varilla de acero pertenece al rango de acero esta normalmente distribuida con  $\sigma = 100$ . Se toman 25 varillas de acero, cada una se mide el límite de elasticidad y resulta  $\bar{x} = 8439/16$ . Cálculo un intervalo de confianza de nivel 90% para la verdadera media de límite de elasticidad.

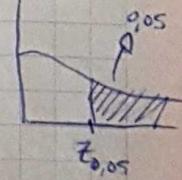
$X_i$ : "límite de elasticidad de una varilla de acero"  $X_i \sim N(\mu, \sigma^2)$   $\sigma = 100$

$X_i$ : "límite de elasticidad de varilla de acero i"  $i = 1, \dots, 25$

$x_1, x_2, \dots, x_{25}$  M.A. de varia  $X$ .  $\bar{x} = 8439/16$

$$1 - \alpha = 0,9 \rightarrow \alpha = 0,1 \rightarrow \frac{\alpha}{2} = 0,05 \quad \left(\bar{X} - z_{\frac{\alpha}{2}} \sqrt{\frac{\sigma^2}{n}}, \bar{X} + z_{\frac{\alpha}{2}} \sqrt{\frac{\sigma^2}{n}}\right)$$

$$z_{0,05} = 1,65$$



$$\rightarrow \left(8439 - 1,65 \sqrt{\frac{100^2}{25}}, 8439 + 1,65 \sqrt{\frac{100^2}{25}}\right) = (8406, 8472)$$

$$L = 8472 - 8406 = 66$$

$$\text{Intervalo} \quad 1-\alpha = 0,92 \quad \alpha = 0,08 \quad \frac{\alpha}{2} = 0,04 \quad Z_{0,04} = 1,76$$

$$(8439 - 1,76 \sqrt{\frac{100^2}{n}}, 8439 + 1,76 \sqrt{\frac{100^2}{n}}) = (8403,8, 8474,2)$$

$L = 70,4 \rightarrow$  aumentó la longitud

Observación:  $D(\bar{X} - z_{\frac{\alpha}{2}} \sqrt{\frac{\sigma^2}{n}}, \bar{X} + z_{\frac{\alpha}{2}} \sqrt{\frac{\sigma^2}{n}})$  está centrado en  $\bar{X}$

$$\text{② La longitud } L = \bar{X} + z_{\frac{\alpha}{2}} \sqrt{\frac{\sigma^2}{n}} - (\bar{X} - z_{\frac{\alpha}{2}} \sqrt{\frac{\sigma^2}{n}}) = \boxed{2 z_{\frac{\alpha}{2}} \sqrt{\frac{\sigma^2}{n}}}$$

Notar que: si dejamos  $n$  fijo y aumenta  $1-\alpha$  (disminuye  $\alpha$ ), entonces  $\frac{z_{\alpha}}{2}$  aumenta  $\therefore L$  aumenta

Si  $1-\alpha$  se deja fijo y aumenta  $n$  entonces  $L$  disminuye (aumenta la precisión de la estimación)

Se puede plantear que tomando  $n$  demuestra  $X$  necesita para que la longitud  $L$  sea menor a  $l$ . ( $l$  se fija de antemano)

$$L = 2 z_{\frac{\alpha}{2}} \sqrt{\frac{\sigma^2}{n}} \leq l \rightarrow \left( \frac{2 z_{\frac{\alpha}{2}} \sigma}{l} \right)^2 \leq n$$

y: que tamaño de muestra se necesita para que el intervalo de nivel 90% sea menor a la mitad.

$$L = 2 \cdot 1,65 \sqrt{\frac{100^2}{n}} \leq 33 \rightarrow \left( \frac{2 \cdot 1,65 \cdot 100}{33} \right)^2 \leq n \quad \therefore \boxed{n \geq 100}$$

Si  $X$  estima puntualmente  $\mu$  con  $\bar{X}$ , se comete un error, y nota que ese  $E \leq \frac{L}{2}$  con una confianza de  $(1-\alpha)100\%$ .

